

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Программная инженерия»

УДК 004.422.832

УТВЕРЖДАЮ
Академический руководитель
образовательной программы
«Программная инженерия»,
старший преподаватель департамента
программной инженерии

«16» _____ мая 2025 г. Н.А. Павлочев

Выпускная квалификационная работа

на тему «Клиентская часть умного корпуса текстов СМИ и сервис для
автоматического сбора и обработки новостей»

по направлению подготовки 09.03.04 «Программная инженерия»

Научный руководитель

Доцент департамента программной
инженерии факультета компьютерных наук

Должность, место работы

канд. комп. наук.

ученая степень, ученое звание

А.А. Мицюк

И.О. Фамилия

16.05.2025

Подпись, Дата

Выполнил

студент группы БПИ217

4 курса бакалавриата
образовательной программы
«Программная инженерия»

М.Д. Пересторонин

И.О. Фамилия



16.05.2025

Подпись, Дата

Москва 2025

Реферат

В современном мире каждому бизнесу, вне зависимости от его размеров, приходится работать с колоссальным объемом новостных данных. Важно вовремя получать информацию о новых законах, тарифах, налогах, и правилах, следить за действиями конкурентов, а также наблюдать за прочими сторонними факторами, способными повлиять на существующих или потенциальных клиентов. Данная проблема особенно актуальна для компаний, ведущих международную деятельность, ведь им важно быть в курсе не только локальных событий, но и следить за новостями из других стран.

Сегодня современные крупные компании содержат целые отделы, либо нанимают специализированные агентства, занимающиеся мониторингом популярных новостных изданий. Сотрудники таких организаций целый день собирают информацию из СМИ и других специализированных источников: сайтов конкурентов, поставщиков, государственных органов. Затем они формируют полученную информацию в тематические дайджесты, которые отправляют на почту сотрудникам компании-заказчика. Каждый такой дайджест содержит в себе только самую важную информацию из проанализированных новостей, представленную в кратком и легко читаемом формате. Понятно, что чем больше в организации узкоспециализированных отделов, тем больше тематических дайджестов нужно, чтобы покрыть все информационные нужды компании. Тут важно отметить, что сбор и анализ информации, классификация ее по интересующим темам, формирование и отправка дайджестов – это невероятно сложный, трудоемкий и требовательный процесс, который забирает на себя огромное количество времени и ресурсов. Умный корпус текстов СМИ призван автоматизировать описанные выше задачи, полностью взяв на себя сбор, хранение, классификацию и анализ релевантных новостей, а также формирование и рассылку новостных дайджестов.

Данная работа посвящена разработке клиентской части веб приложения умного корпуса текстов СМИ “Crosswords”, а также ETL системе по сбору и классификации статей и последующему составлению из них дайджестов.

Ключевые слова: frontend, ETL, pipeline, дайджест, СМИ, классификация, микросервис.

Работа содержит 51 страницу, 3 главы, 34 иллюстраций, 7 источников.

Abstract

In the modern world, every business, regardless of its size, has to deal with vast amounts of information. It's crucial to stay updated on new laws, tariffs, taxes, and regulations, monitor competitors' actions, and track external factors that could impact current or potential clients. This issue is particularly relevant for companies engaged in international activities, as they need to stay informed about both local and global news.

Modern large companies maintain entire departments or hire specialized agencies to monitor popular news outlets. Employees of such organizations spend entire days collecting information from media and other specialized sources, such as the websites of competitors, suppliers, and government agencies. They then compile this information into thematic digests, which are emailed to the client company's staff. Each digest contains only the most critical information from the analyzed news, presented in a concise and easily readable format. Naturally, the more specialized departments the company has, the more thematic digests are needed to cover all its information needs. It's worth noting that collecting and analyzing information, classifying it by relevant topics, and creating and distributing digests is an incredibly complex, time-consuming, and resource-intensive process.

The intelligent media text corpus is designed to automate these tasks, fully handling the collection, storage, classification, and analysis of relevant news, as well as the creation and distribution of news digests.

This study is dedicated to developing the client-side of the "Crosswords" smart media text corpus web application, as well as an ETL system for collecting and classifying articles as well as compiling them into digests.

Keywords: frontend, ETL, pipeline, digest, media, classification, microservice.

The work contains 51 pages, 3 chapters, 34 illustrations, and 7 sources

Термины и определения

ETL (Extract, Transform, Load) – это процесс извлечения данных из различных источников, их преобразования в нужный формат и последующей загрузки в другую систему

Pipeline – это последовательность этапов обработки данных, где выход одного шага служит входом для следующего

Микросервисная архитектура – это способ организации программного обеспечения, при котором система состоит из множества независимых сервисов, взаимодействующих через API. Каждый микросервис выполняет ограниченную бизнес-логику, разрабатывается, разворачивается и масштабируется отдельно, что повышает гибкость, отказоустойчивость и удобство сопровождения системы

Классификация (в контексте машинного обучения) – это задача, при которой модель предсказывает категорию или класс для входных данных

Dashboard (Дашборд) – это визуальный интерфейс, который отображает ключевые показатели и данные в реальном времени, часто в виде графиков, диаграмм и таблиц

LLM (Large Language Model, большая языковая модель) – это тип модели машинного обучения, основанный на нейросетях и обученный на больших объемах текстовых данных

Airflow DAG (Directed Acyclic Graph) – это структура в Apache Airflow, представляющая собой ориентированный ациклический граф для описания и управления последовательностью задач (операций), которые должны быть выполнены в определенном порядке. DAG используется для организации и автоматизации рабочих процессов (workflows), где каждая задача представляет собой отдельный этап обработки данных. В DAG задачи могут выполняться параллельно или последовательно, в зависимости от их зависимостей

Web scraper (веб скрапер) – это программа или скрипт, предназначенный для автоматизированного сбора данных с веб-страниц. Веб-скраперы используют технологии парсинга HTML-кода, чтобы извлекать структурированную информацию (например, тексты, изображения, ссылки, метаданные) с сайтов

JSON (JavaScript Object Notation) – это текстовый формат обмена данными, основанный на синтаксисе объектов JavaScript. Используется для хранения и передачи структурированной информации

Корпус – это электронная коллекция текстов, собранная по определённым принципам предназначенная для дальнейшего анализа

Содержание

Введение.....	6
1. Предметная область и существующие решения.....	8
1.1. Описание предметной области.....	8
1.2. Описание рынка агрегаторов и средств автоматического мониторинга СМИ	9
1.3. Flipboard	10
1.4. Feedly	14
1.5. Seldon News.....	17
1.6. Яндекс Дзен.....	19
1.7. Анализ конкурентных решений	22
Выводы по главе.....	23
2. Проектирование системы, используемые технологии.....	24
2.1. Требования к программе.....	24
2.2. Описание архитектуры приложения.....	25
2.3. Проектирование ETL пайплайна.....	26
2.4. Создание веб версии корпуса.....	29
Выводы по главе.....	31
3. Обзор основного функционала и детали его реализации	32
3.1. Клиентская часть	32
3.1.1. Авторизация	32
3.1.2. Домашняя страница.....	33
3.1.3. Страница со всеми документами	34
3.1.4. Просмотр, редактирование и удаление статьи	35
3.1.5. Принцип работы подписок и дайджестов	38
3.1.6. Просмотр дайджестов и подписок.....	39
3.1.7. Просмотр дайджеста.....	41
3.1.8. Система управления уведомлениями	42
3.1.9. Создание/редактирование подписки.....	43
3.1.10. Выгрузка статей из корпуса.....	45
3.2. Сервис для автоматического сбора и обработки новостей.....	46
3.2.1. Веб скрапер	46
3.2.2. Kafka.....	46
3.2.3. Сервис классификации.....	46
3.2.4. Сервис создания дайджестов.....	47
Выводы по главе.....	47
Заключение.....	49
Источники.....	50

Введение

Основная тема дипломного проекта – создание адаптивной веб-версии умного корпуса текстов СМИ, а также разработка сервиса для автоматического сбора и классификации новостей, составления дайджестов. Веб-версия должна позволять пользователю находить интересующие его новости с помощью инструментов фильтрации и поиска, просматривать найденные статьи, добавлять к ним заметки и аннотации, добавлять статьи в папки, просматривать свои приватные и общие дайджесты, заказывать создание персонализированных дайджестов и переходить к portalу со статистикой.

Основная задача системы автоматического сбора и классификации новостей заключается в получении новых статей из перечня источников СМИ, их классификации, написании краткого содержания для каждой статьи и создании на основе этого дайджестов. Сервис состоит из нескольких программных компонентов: компонент для сбора новостей, компонент для классификации и компонент для составления дайджестов. Каждый из этих компонентов представлен в виде отдельного микросервиса. Все эти сервисы вместе образуют единый ETL пайплайн.

Важно отметить, что корпус должен ежедневно обрабатывать огромное количество информации. Это означает, что описанный ранее ETL пайплайн должен быть адаптирован к работе с большими объемами данных и обладать высокой отказоустойчивостью. Эти факторы в первую очередь было необходимо учесть в процессе разработки архитектуры и выбора средств реализации.

Данная работа подразумевает выполнение следующих задач:

- 1) Проведение анализа конкурентных решений на рынке агрегаторов СМИ,
- 2) Составление требований к продукту на основе бизнес-целей и желаний заказчика,
- 3) Проектирование архитектуры ETL решения,
- 4) Выбор технических средств реализации,
- 5) Составление и согласование спецификации API для взаимодействия с другими компонентами корпуса,
- 6) Разработка ETL пайплайна,
- 7) Разработка веб версии умного корпуса СМИ,
- 8) Разработка технической документации.

Данная работа состоит из трех глав

В первой главе приведены результаты анализа популярных аналогов, доступных на рынке агрегаторов СМИ. Каждый аналог сравнивался с разрабатываемым решением по

набору заданных критериев. Основной задачей данного анализа является демонстрация основных отличий продукта, разрабатываемого в рамках выпускной квалификационной работы от других подобных решений.

Вторая глава посвящена разбору основных архитектурных решений, принятых в процессе проектирования и разработки программы, а также обоснованию выбора ключевых средств реализации, используемых во время выполнения выпускной квалификационной работы.

Третья глава представляет собой обзор ключевого функционала, предоставляемого разработанным ПО. В этом разделе содержится описание реализации основных компонентов, представлены основные страницы клиентской части умного корпуса, описаны алгоритмы работы веб-скрапера, сервиса классификации и сервиса составления дайджестов.

1. Предметная область и существующие решения

1.1. Описание предметной области

Несмотря на то, что умный корпус текстов СМИ включает в себя функционал для сбора и отображения данных из различных источников, данный проект не является обычным агрегатором новостей. Его функционал более обширен и персонализирован под требования заказчика - АО "ТБАНК". Корпус не только собирает новости из различных СМИ, но и классифицирует их по тегам, составляет для каждой новости «выжимку» — ее краткую версию, предоставляет мощные инструменты для фильтрации и поиска, а также позволяет пользователям заказывать составление персонализированных дайджестов, составленных из новостей, соответствующих критериям, указанным пользователем.

Примером потенциального пользователя разрабатываемого ПО может быть сотрудник банка, работающий в отделе трансграничных переводов, который должен быть в курсе новостей в своей профессиональной сфере. Ему важно оперативно получать информацию о правилах международных переводов в странах-партнерах, а также следить за новостями и объявлениями от центральных банков, международными тарифами, ограничениями и санкциями. Для этого ему нужно ежедневно читать огромное количество источников — от известных изданий, таких как «Коммерсантъ» или «Интерфакс», до менее популярных, например, сайты центробанков стран СНГ. Кроме того, необходимо обработать и отфильтровать нерелевантную информацию, выделить суть из актуальных новостей, а также сохранить ссылки на источники для последующих обращений. Эта сложная и ответственной работа может быть эффективно автоматизирована с использованием моделей машинного обучения, чем и занимается корпус текстов СМИ.

Т. к. корпус хранит в себе большое количество новостных статей, а также предоставляет инструменты для их поиска и фильтрации, было решено использовать обширную базу данных проекта для проведения различных исследований в областях журналистики, лингвистики и социологии. Для этого корпус был оснащен дополнительным исследовательским функционалом. Пользователи могут оставлять заметки и аннотации к статьям, добавлять их в папки, выгружать содержимое папок в формате JSON, а также визуализировать статистическую информацию о корпусе с помощью дашбордов. Кроме того, обратная связь от пользователей (например, оценка качества классификации) позволяет использовать эти данные для создания и дообучения моделей машинного обучения.

1.2. Описание рынка агрегаторов и средств автоматического мониторинга СМИ

Как было установлено ранее, умный корпус текстов СМИ содержит функционал, выходящий за рамки обычного агрегатора новостей. Это достигается благодаря возможности корпуса самостоятельно анализировать СМИ, извлекать суть из нескольких новостей одновременно, объединяя статьи из различных источников в один краткий дайджест. Кроме того, корпус предоставляет спектр аналитических инструментов, которые могут быть использованы для проведения исследовательских работ на основе большого количества хранимых статей.

Сперва хочется отметить, что конкурентный анализ не выявил ни одного продукта, предлагающего в точности такой же функционал, как корпус. Однако это не означает, что у него нет конкурентов. Наиболее схожими по функционалу являются новостные агрегаторы и системы мониторинга СМИ. Среди популярных решений можно выделить Flipboard, Яндекс Дзен, Feedly, Seldon.News, Smart News и Рамблер/Новости. К менее известным и более нишевым относятся uCrawler и RedInfoTools. Каждое из перечисленных решений обладает своими уникальными особенностями. Одни специализируются на мгновенной доставке свежих новостей с уведомлениями для пользователей, другие - на автоматической классификации и категоризации поступающих новостей, а третьи - на развитых рекомендательных системах, показывающих пользователю только то, что ему может понравиться. Тем не менее, не было выявлено единого решения, которое идеально подстраивается под информационные нужды компании с дополнительным исследовательским функционалом (за исключением мониторинговых агентств, таких как Exlibris, где значительная часть работы выполняется вручную). Ниже мы рассмотрим несколько основных конкурентов, а затем рассмотрим результаты сравнительного анализа.

Однако перед переходом к анализу конкурентов необходимо отметить, что большое количество рассмотренных аналогов содержат как мобильную, так и веб версию. Т. к. данная работа посвящена разработке именно веб версии корпуса, исследования аналогов будет произведено на основе веб версий сервисов конкурентов за исключением тех случаев, когда у сервиса отсутствует веб версия, либо ее функционал заметно ограничен.

1.3. Flipboard

Flipboard — это агрегатор новостей, представляющий собой платформу для персонализированного потребления информации, объединяющую статьи из различных источников в удобном для пользователя формате. Основной принцип работы Flipboard заключается в агрегировании и персонализации контента, что достигается за счет анализа пользовательских предпочтений и автоматической фильтрации информации. У каждого пользователя есть своя персональная лента — лента “для вас”. Она подирается алгоритмами Flipboard на основе пользовательского поведения. Пользователь может подписаться на интересующие его теги, чтобы лично персонализировать содержимое этой ленты (рисунок 1).




Рисунок 1 - Лента "Для вас"

В веб версии каждая статья представлена отдельной карточкой, при нажатии на которую открывается сайт, содержащий оригинальную статью. По сути, веб версия просто упрощает задачу поиска новостей благодаря их автоматической классификации путем присвоения тегов. По этим тегам в дальнейшем можно осуществлять фильтрацию (рисунок 2). Сразу хочется отметить, что данный функционал представлен в таком же виде в умном корпусе текстов СМИ.




Рисунок 2 - Поиск в Flipboard

При помощи Flipboard пользователи могут не только читать новости, но и делиться ими в различных форматах. Помимо привычной пересылки ссылки на понравившуюся статью через мессенджер или электронную почту, Flipboard предлагает пользователям более организованный способ делиться статьями – журналы (рисунок 3).




Рисунок 3 - Добавление статьи в журнал

Пользовательский журнал представляет собой набор статей, которые этот самый пользователь нашел на Flipboard и добавил туда. Например, можно завести кулинарный журнал, где пользователь может выкладывать те рецепты из интернета, которые он реально самостоятельно попробовал приготовить. Другие же пользователи, доверяющие вкусам автора, могут подписаться на его журнал, чтобы просматривать его содержимое. Это чем-

то напоминает систему плейлистов, активно использующихся в музыкальных и видео сервисах.

Как уже говорилось ранее, при нажатии на название статьи в веб версии flipboard, пользователя переводят на страницу оригинала, однако в мобильном приложении просмотр представлен в двух режимах: "Веб" и "Чтение" (рисунок 4). На это важно обратить внимание, т. к. скорее всего flipboard использует веб скрапинг для получения информации для режима чтения, что напрямую относится к разрабатываемому в рамках ВКР функционалу.




Рисунок 4 - Режимы просмотра статьи

Режим «Веб» открывает внутри приложения HTML страницу сайта – источника вместе со всеми ее особенностями (например, всплывающие окна, цветовое оформление, логотип, отдельные специфичные UI элементы). Режим «Чтение» в свою очередь переносит только текст статьи, картинки и прочую метаинформацию внутрь приложения. Это придает статьям более стандартизированный вид, т. к. цвет фона, шрифты, расположение информации (например дата загрузки и автор статьи) не меняются от статьи к статье. Важно отметить, что этот режим не всегда работает идеально гладко. Зачастую, программе не удается получить ту или иную информацию с сайта – источника. Как результат, при просмотре страницы в режиме "Чтение" порой отображается некорректная информация, появляются визуальные артефакты, отсутствует некоторая метаинформация, к тексту статьи добавляется текст рекламы, бывшей на сайте на момент скрапинга и множество других мелких недочетов, которые напрямую не препятствуют просмотру контента, но осложняют его потребление (рисунок 5).




Рисунок 5 - Часть рекламы попала в текст статьи, визуальный артефакт.

Несмотря на очевидные преимущества, Flipboard имеет ряд ограничений, связанных с зависимостью от источников контента и алгоритмов персонализации. Платформа не осуществляет собственный журналистский анализ новостей, а лишь структурирует доступную информацию. Кроме того, алгоритмическая персонализация может приводить к эффекту информационного пузыря, когда пользователи получают только тот контент, который соответствует их текущим предпочтениям, без возможности широкого обзора событий. Также хочется отметить, что Flipboard всего лишь предоставляет удобный инструмент для просмотра новостей, он не занимается их глубоким анализом. Иными словами, Flipboard не может прочитать десятки новостей по определенной теме и выслать пользователю только их суть, представленную в виде дайджеста. Даже с отлично работающей системой рекомендательных алгоритмов, пользователю все равно необходимо читать новости самостоятельно одну за другой. Еще одной проблемой является, что Flipboard также покрывает далеко не все новостные издания. Скорее наоборот, список СМИ доступных в Flipboard весьма ограничен. Поэтому, если компания захочет получать новости из каких-то специализированных источников, например центробанков стран СНГ, то она никак не может реализовать эту потребность через Flipboard. Сюда же хочется добавить,

что несмотря на наличие в Flipboard новостей на русском языке, приложение не работает в РФ, хоть и остается доступным в Российском App Store и Google Play.

1.4. Feedly

Feedly — это современный агрегатор новостей и RSS-ридер, предназначенный для сбора, структурирования и персонализированного отображения контента из различных источников. Разработанный как альтернатива устаревшему Google Reader, сервис быстро завоевал популярность среди пользователей, которым важно централизованное управление новостной информацией

Основной принцип работы Feedly заключается в использовании RSS-каналов, которые позволяют пользователям подписываться на обновления интересующих их сайтов и получать новости в единой ленте. Кроме того, сервис предлагает расширенные возможности фильтрации и категоризации контента, что делает его удобным инструментом для сегментирования информации по тематикам, источникам и ключевым словам. Пользователю представлены две ленты – "Me" и "Explore". Секция "Explore" показывает пользователю ленту, состоящую из популярных на данный момент новостей. Эти новости организованы в небольшие группы, каждая группа – имеет какую-то свою тематику, например "Технологии" или "Еда" (рисунок 6).




Рисунок 6 - Секция "Explore"

Важно отметить, что сами статьи как правило не хранятся на Feedly. Программа в основном собирает только заголовки, фото и метаданные. А для того, чтобы прочитать статью целиком, необходимо открыть ее в браузере, что делается путем нажатия кнопки "Visit Website" в нижнем углу страницы со статьей (рисунок 7). После нажатия на такую кнопку приложение переносит пользователя в браузер, где открывает соответствующую статью.




Рисунок 7 - Представление статьи в Feedly

Другой выдающейся частью Feedly является секция "Follow Sources", тут пользователю предлагается выбрать интересующие его источники (рисунок 8). Сами источники разбиты по категориям, однако важно отметить, что подписаться на целую категорию у пользователя не выйдет. В отличие от корпуса, рассматриваемый сервис разграничивает по категориям издательства, но не сами статьи. Данная секция также представляет пользователю несколько популярных источников и представляет поиск, где пользователь может сам найти интересующие его издательства. Однако важно отметить, что пользователь может лишь выбирать из предложенных опций, он не может добавить или источник самостоятельно. Это в очередной раз показывает, почему крупные компании, как в нашем случае АО "ТБАНК", заказывают разработку собственных решений, таких как умный корпус текстов СМИ. Подобным агрегаторам новостей, несмотря на высокий уровень персонализации все равно не хватает гибкости. В этом плане, умный корпус текстов СМИ, хоть и не содержит функционала по динамическому и автономному

добавлению источников, категорий или тегов, все равно разрабатывался под конкретные нужды компании и содержит весь необходимый ей функционал.

При подписке на источник, пользователя просят добавить этот источник в одну из своих папок. Каждая такая папка представляет собой отдельную новостную ленту. Т. е. при добавлении нескольких источников в одну папку, пользователь как бы собирает собственную ленту, состоящую из новостей, собранных из состоящих в папке источников.

Также хочется добавить, что в этой секции можно подключить получение постов из заданных пользователем сообществ на Reddit, а также интегрировать свою почту с Feedly, чтобы прочие новостные рассылки напрямую встраивались в ленту сервиса. Однако эта интеграция доступна только для подписчиков Feedly pro – платной подписке сервиса.

Важно заметить, что Feedly также обладает AI ассистентом, который выбирает наиболее




Рисунок 8 - Секция "Follow Sources"

интересные для пользователя статьи на основе его предпочтений. Можно указать перечень интересующих тем, а также выбрать тип источников, например «Национальные газеты» или «Тех блоги» (рисунок 9).

Однако этот ассистент не может самостоятельно прочитать несколько статей по заданной тематике и составить на их основе какую-то краткую выжимку. Т. е. пользователю все равно придется читать все новости самостоятельно. В этом и кроется главное различие Feedly от разрабатываемого проекта. Умный корпус использует ИИ не только для подборки новостей, но и для их анализа, благодаря его богатой системе подписок и дайджестов. Помимо этого, Feedly не имеет встроенных средств визуализации данных, как и другого важного исследовательского функционала (например возможность оставлять аннотации и комментарии к статьям).




Рисунок 9 - ИИ ассистент

1.5. Seldon News

Seldon.News — это современный агрегатор новостей и инструмент мониторинга СМИ, разработанный для комплексного сбора, анализа и обработки новостной информации. Сервис предназначен для пользователей, которым необходимо оперативно отслеживать актуальные события, анализировать тренды и получать персонализированную ленту новостей из множества источников. Основной принцип работы Seldon.News заключается в автоматическом агрегировании контента из различных СМИ, включая федеральные и региональные издания, государственные сайты, отраслевые ресурсы и другие источники. В отличие от традиционных новостных агрегаторов, Seldon.News предлагает расширенные функции фильтрации и аналитики, позволяя пользователям настраивать мониторинг новостей, по ключевым словам, тематикам, географическому признаку и другим параметрам. С технической точки зрения Seldon.News использует методы машинного обучения и обработки естественного языка (NLP) для классификации новостного контента, выделения ключевых тем и анализа информационного фона. Это позволяет системе не только собирать новости, но и определять их актуальность, степень значимости и возможное влияние на пользователей. Seldon News также обладает аналитическими инструментами и средствами визуализации информации (рисунок 10).




Рисунок 11 - Визуализация рейтинга медийных объектов в Seldon News

Помимо визуализации статистических данных Seldon news также может предложить своим пользователям аналитику статей. Сервис в отдельной секции показывает ключевые лица, места и компании, о которых идет речь в статье (рисунок 11).




Рисунок 12 - Анализ ключевых фигур в статье

Важно также отметить, что Seldon News имеет секцию с дайджестами, однако эти дайджесты сильно отличаются от тех, что используются в умном корпусе текстов СМИ. Дайджест в Seldon News – это не единый документ, содержащий только всю важную информацию из нескольких источников по какой-то конкретной теме, а просто подборка различных популярных новостных статей. Он не сокращает время, необходимое для исследования какой-либо тематики, пользователю все равно придется прочитать все статьи целиком.

1.6. Яндекс Дзен

Яндекс Дзен — это платформа для публикации и потребления контента, разработанная компанией Яндекс. В отличие от традиционных новостных агрегаторов, Дзен ориентирован не только на сбор и отображение новостей, но и на персонализированный подбор статей на основе алгоритмов машинного обучения. Сервис анализирует поведенческие факторы пользователей и формирует ленту рекомендаций, соответствующую их интересам. Основной принцип работы Яндекс Дзена заключается в автоматическом отборе контента с помощью технологий обработки естественного языка (NLP) и машинного обучения. Платформа анализирует, какие материалы пользователь читает, сколько времени проводит на странице, какие темы вызывают больший интерес, и на основе этих данных подстраивает выдачу. Такой подход позволяет Дзену формировать персонализированную ленту, которая динамически адаптируется под предпочтения конкретного человека. С технической точки зрения Яндекс Дзен представляет собой экосистему, в которой объединены контент от медиа, блогеров и независимых авторов. Авторы могут размещать статьи, видео и другие материалы, получая монетизацию за просмотры. Т. е. Дзен представляет собой не просто агрегатор новостей, но и целую площадку для размещения статей независимых авторов. Секция "Новости" в Яндекс дзен (рисунок 12) представляет собой список новостей, где каждая новость представлена карточкой. Нажатие на такую карточку переводит пользователя на сайт источник.




Рисунок 13 - Секция "Новости"

Т. е. несмотря на то, что Яндекс дзен и имеет функционал по агрегации новостей, это не является его основным функционалом. Дзен показывает себя куда лучше при работе с материалами, публикуемыми членами сообщества платформы. У таких статей куда лучше работает рекомендательная система, есть возможность оставления лайков и написания комментариев. Как итог, дзен больше похож на социальную сеть, форум или даже платформу для сообществ, чем на агрегатор новостей.

1.7. UCrawler

UCrawler представляет собой инструмент для автоматического сбора данных с веб-сайтов. Согласно информации, размещённой на официальном сайте uCrawler, данный сервис способен извлекать данные с любых веб-ресурсов и передавать их в системы клиента в различных форматах, включая JSON, XML, RSS, либо напрямую экспортировать результаты веб-скрапинга в реляционные базы данных, такие как PostgreSQL, Oracle и MySQL. Для использования сервиса пользователю достаточно лишь указать URL-адреса интересующих его источников. Как и в корпусе, процесс сбора статей полностью автоматизирован. Важной особенностью uCrawler является унифицированный формат выходных данных, обеспечивающий одинаковую структуру для информации, полученной из различных источников (рисунок 13).

```
"domain" : "www.politico.com"
"api_url" : "https://console.ucrawler.app/api/article/25062021/14021308499559735236/"
"html" : "<img src='https://static.politico.com/dims4/default/c225bac/2147483647/resize/1160x%3E/quality/90/?url=https%3A%2F%2Fstatic.politico.com%2F80%2F19%2Fb...'>"
"text" : "A sign for the Department of Justice Federal Bureau of Prisons. | AP Photo/Mark Lennihan, File The Bureau of Prisons has partially paused onboarding n..."
"lang" : "en"
"url" : "https://www.politico.com/news/2021/06/25/bureau-of-prisons-cash-crunch-496311"
"iframes" : []
"pub_time" : "2021-06-25T18:58:30.211Z"
"meta_images" : [ 1 item
  0 : "https://static.politico.com/80/19/b4e1937c41588617cf669d4bd50f/ap21161735784550-1.jpg"
]
"score" : 20
"title" : "Union boss: Bureau of Prisons faces dangerous cash crunch"
"images" : [ 1 item
  0 : { 6 items
    "url" : "https://static.politico.com/dims4/default/c225bac/2147483647/resize/1160x%3E/quality/90/?url=https%3A%2F%2Fstatic.politico.com%2F80%2F19%2Fb4e1937c415..."
    "caption" : NULL
    "length" : 349434
    "format" : "JPEG"
    "width" : 1160
    "height" : 773
  }
]
"sources" : [ 1 item
  0 : { 4 items
    "group" : 6
    "group_name" : "World News"
    "source" : 122
    "source_name" : "politico.com"
  }
]
"icons" : 18 items
  0 - 10
  10 - 18
"link" : "https://www.politico.com/news/2021/06/25/bureau-of-prisons-cash-crunch-496311"
"video" : []
"id" : "14021308499559735236"
```

Рисунок 13 - Единый формат JSON, используемый для представления любой статьи, получаемой через uCrawler

Для работы с собранными новостями uCrawler предоставляет инструменты поиска и фильтрации, позволяющие задавать ключевые слова, перечень источников и временной диапазон. Аналогичные функции фильтрации реализованы и в разрабатываемом «Умном корпусе текстов СМИ». Однако, в отличие от uCrawler, «Умный корпус текстов СМИ» дополнительно поддерживает фильтрацию новостей по тегам и пользовательским папкам, а также предлагает три различных режима поиска. Однако uCrawler тоже обладает рядом уникальных возможностей поиска, таких как выбор формата вывода результатов (JSON или XML), настройка максимального количества возвращаемых текстов и ограничение объёма текста по количеству символов. Кроме того, uCrawler поддерживает работу с RSS и предоставляет открытый API для взаимодействия с внешними системами.

В сравнении с «Умным корпусом текстов СМИ» функционал uCrawler ограничивается задачей сбора новостных статей. Хотя система способна группировать схожие по содержанию материалы, она не обладает столь развитой системой тегов, как в разрабатываемом решении. Кроме того, uCrawler не предоставляет аналитических инструментов, за исключением базового поиска, не выполняет классификацию новостей и не формирует персонализированные дайджесты. Таким образом, uCrawler скорее целесообразно рассматривать как вспомогательный инструмент для сбора данных, который даже в будущем может быть интегрирован в «Умный корпус текстов СМИ» для выполнения задачи веб скрапинга, а не как полноценный конкурент разрабатываемого решения. Важно также отметить, что uCrawler распространяется по модели подписки (рисунок 14), стоимость которой зависит от количества поддерживаемых источников. При этом оплатить эту подписку на данный момент из России, как и из некоторых других стран нельзя.

PRO 10 10 sources €10/mo Buy now	PRO 20 20 sources €20/mo Buy now	PRO 50 50 sources €50/mo Buy now	PRO 100 100 sources €100/mo Buy now
PRO 200 200 sources €200/mo Buy now	PRO 300 300 sources €300/mo Buy now	PRO 500 500 sources €500/mo Buy now	PRO 1000 1000 sources €1000/mo Buy now

Рисунок 14 - Стоимость использования uCrawler

1.8. Анализ конкурентных решений

Результаты конкурентного анализа приведены ниже (таблица 1)

Таблица 1 – результаты конкурентного анализа.

Критерий/название	УКТСМИ	uCrawler	Flipboard	Smart News	Feedly	Seldon. News	Яндекс Дзен
Персонализированные дайджесты	+	-	+	+	+	+	+ -
Расширенная поисковая система	+	+ -	- +	-	+ -	+ -	+
Персонализированные уведомления о появлении интересующих новостей	+	-	+	+	+	-	+
Выгрузка новостей	+	+	-	-	+	+	-
Работа с российскими СМИ	+	+	+	-	+	+	+
Автоматическая категоризация новостей	+	+ -	+	+	+	+	+
Настраиваемая статистика, дашборды	+	-	-	-	-	+	+ -
Составление "выжимок" из статей	+	-	-	-	+	-	+
Мобильное приложение	+	-	+	+	+	-	+
Web версия	+	+	+	-	+	+	+
Разметка статей	+	-	-	-	+	-	-
Оставление заметок к статьям/дайджестам	+	-	-	-	+	-	-

Продолжение таблицы 1

Добавление в избранное	+	-	+	-	+	-	-
API	-	+	-	-	+	-	-

Выводы по главе

В данной главе приведен краткий обзор предметной области, описаны основные отличия умного корпуса СМИ от существующих на рынке агрегаторов и систем мониторинга новостей, а также представлены результаты исследования рынка подобных решений и, наконец, представлены результаты конкурентного анализа, сравнивающего умный корпус СМИ с наиболее близкими по функционалу аналогами.

Анализ показал, что несмотря на наличие множества новостных агрегаторов и сервисов мониторинга, на ранке нет решения, обладающего таким же уровнем автоматизации, персонализации и аналитических возможностей, как разрабатываемый продукт. В отличие от существующих решений, умный корпус СМИ не только собирает новости, но и классифицирует их, формирует дайджесты и предоставляет инструменты для глубокого анализа данных.

Полученные результаты демонстрируют актуальность разработки и подтверждают наличие потребности в разрабатываемом продукте. Уникальные возможности корпуса, такие как богатые инструментарий поиска и фильтрации, автоматическая генерация дайджестов и поддержка исследовательской деятельности, выделяют его среди конкурентов, делая его ценным инструментом для бизнеса, аналитиков и исследователей. Еще одним доказательством актуальности проекта служит наличие заказчика, под чьи нужды и разрабатывается данный проект – АО «ТБАНК».

2. Проектирование системы, используемые технологии

2.1. Требования к программе

Клиентская часть:

- Авторизация,
- Регистрация,
- Просмотр загруженных статей,
- Просмотр дайджестов за прошедшие дни,
- Заказ на формирование дайджестов по определенной тематике путем указания перечня тегов, источников и подписчиков (создание подписки),
- Фильтрация, сортировка, поиск статей/дайджестов по дате, тегам, названию, изданию
- Поиск по ID, синтаксический и точный,
- Добавление/редактирование/удаление статей,
- Добавление/удаление статьи в пользовательскую папку,
- Добавление заметок и аннотаций к статьям,
- Выгрузка статей по папкам,
- Добавление пользовательского рейтинга классификации к новостным статьям и рейтинга качества составления дайджеста к дайджестам,
- Редактирование способа получения дайджестов для конкретной подписки.

Сервис для автоматического сбора и классификации данных из новостных изданий:

- Ежедневная выгрузка новостных статей из определенных СМИ,
- Временное хранение собранных новостей,
- Классификация, составление краткого содержания каждой выгруженной статьи,
- Передача результатов классификации и составленного краткого содержания на backend,
- Составление персонализированных дайджестов на основе новостей при помощи LLM,
- Отправка дайджестов на backend.

2.2. Описание архитектуры приложения

Для реализации умного корпуса текстов СМИ была применена микросервисная архитектура, ниже приведена схема основных компонент проекта (рисунок 15):




Рисунок 15 - Диаграмма архитектуры корпуса

Желтым тут отмечены те компоненты, реализация и использование которых относятся к клиентской части и системе автоматического сбора новостей, их классификации и составлению дайджестов (теме ВКР).

Сперва хочется отметить основные преимущества использования микросервисной архитектуры, которые послужили обоснованием для ее выбора. Данная архитектура позволяет каждому разработчику работать над своим набором сервисов независимо от других членов команды. Главное лишь предварительно обозначить зоны ответственности и согласовать спецификацию API. Причем при составлении грамотной спецификации, разработчики могут работать над своими компонентами в удобном для себя темпе и реализовывать свои сервисы в любом порядке. Более того, этот подход дает каждому разработчику свободу в выборе технических средств реализации и архитектурного подхода своей программной части. Это не только дает возможность разным членам команды работать на своих предпочитаемых языках программирования и фреймворках, но и позволяет им выбирать наиболее подходящие технологии для каждой задачи. Так, например для ежедневного сбора новостей идеально подходит Apache Airflow, который позволяет строить настоящие пайплайны по сбору и обработке данных и запускать их по

расписанию. Кроме вышеперечисленных преимуществ, микросервисная архитектура также предотвращает создание чрезмерной зависимости между компонентами и позволяет собрать систему, где каждый компонент может быть легко заменен без необходимости перерабатывать все остальные. Это в свою очередь делает систему более масштабируемой и гибкой, позволяя с большей легкостью добавлять даже тот функционал, который изначально не планировался, что особенно важно для живого проекта, которому постоянно необходимо расти и совершенствоваться для того, чтобы оставаться конкурентноспособным на рынке. Подобный подход к проектированию системы можно также увидеть во всех реализованных в рамках данной ВКР компонентах корпуса от веб скрапера до клиентской части.

2.3. Проектирование ETL пайплайна

Несомненно, одной из самых ответственных частей архитектуры корпуса текстов СМИ является сбор новостей, их классификация и составление дайджестов на основе собранной информации. Процесс добавления новости в корпус и составления на основе этой и других новостей дайджестов достаточно сложен, так как за его реализацию отвечают несколько архитектурных компонентов, каждый из которых выполняет свой этап в общем пайплайне (рисунок 16).




Рисунок 16 - ETL pipeline

Все начинается с этапа сбора данных, который реализован в виде Airflow DAG, запускающегося каждый вечер по расписанию. Использование Apache Airflow обосновано его мощными возможностями по автоматизации и оркестрации рабочих процессов. Каждый источник новостей представлен отдельной задачей в DAG. Процесс сбора новостей для каждого источника описан в отдельном python файле, что позволяет с легкостью вносить изменения в процесс обработки какого-то конкретного источника без необходимости

менять логику обработки других сайтов, что также заметно упрощает тестирование. Таким образом, если вдруг один из поддерживаемых сайтов резко сменил формат отображения своих статей, то администратор системы может с легкостью выключить обработку этого источника на то время, пока веб скрапер не будет вновь сконфигурирован для работы с ним. Кроме того, разделение на независимые задачи позволяет собирать данные с нескольких сайтов одновременно, т. к. Airflow поддерживает параллельное выполнение задач. Как результат, это значительно ускоряет процесс сбора новостей и их метаданных, особенно учитывая тот факт, что перед сбором статей с одного и того же сайта, скрапер делает небольшую паузу, чтобы избежать излишней нагрузки на сайт источника. Эту особенность важно было учесть в первую очередь из-за этических соображений, а также для того, чтобы избежать блокировок со стороны источников.

В добавок ко всему Airflow можно сконфигурировать так, чтобы в случае возникновения ошибки в процессе выполнения задачи он сам автоматически перезапускал эту задачу через заданный промежуток времени. Так, например, если один из источников будет временно недоступен, airflow самостоятельно попытается обратиться к нему чуть позже. Помимо этого, Airflow имеет встроенный графический интерфейс, который позволяет следить за выполнением задач, просматривать логи, включать и выключать DAG и настраивать многие другие аспекты выполнения программы. Этот функционал также очень важен для разрабатываемой системы, т. к. веб скрапер сильно зависит от реализации структуры сайта-источника и любые правки в эту структуру могут привести к сбою в работе веб скрапера. В этом случае пользовательский интерфейс позволяет сразу понять, где именно произошла ошибка и с чем она связана.

Выбор языка программирования Python для реализации описанного ранее функционала обуславливается требованиями инструмента оркестрации Apache Airflow. Все дело в том, что Airflow DAG, который в нашем случае используется для параллельного сбора статей и их метаданных может быть написан только на языке Python. Кроме этого, Python имеет огромное количество библиотек для веб скрапинга, которые сильно упрощают задачу сбора данных.

После того, как веб скрапер закончил процесс сбора текста новости и ее метаданных, эту самую новость нужно передать сервису классификации. Конечно, сделать это можно было при помощи обычных HTTP запросов, однако такой подход не является достаточно безопасным. Веб скрапер обрабатывает сразу все источники одновременно и может просто перегрузить сервис классификации большим количеством запросов. К тому же оба компонента могут некорректно отработать – веб скрапер может

пострадать от изменения структуры сайта, в то время как модели классификации могут быть временно не доступны, отказаться классифицировать переданный текст из-за встроенных фильтров или перестать работать по любой другой причине. Поэтому необходимо обеспечить асинхронное и независимое взаимодействие этих двух сервисов, чтобы каждый из них мог спокойно работать в своем темпе. Для этого было решено использовать Apache Kafka. Веб скрапер будет записывать полученную информацию в топик `unclassified_news` в то время, как сервис классификации будет слушать `kafka`, принимать данные, классифицировать их и отправлять на серверную часть. Таким образом, благодаря `kafka` полученные веб скрепером статьи будут находиться в безопасности и не будут утеряны, даже если оба сервиса дадут сбой. Такой подход увеличивает отказоустойчивость системы и обеспечивает тот самый асинхронный подход работы сервисов, которого хотелось добиться.

Сам же сервис классификации представляет собой программу на Python, которая читает данные из кафки, преобразует полученную информацию в подходящий запрос и отправляет его большой языковой модели, после чего берет результат работы LLM, валидирует его и отправляет на backend. В конце дня с бекенда подходящие новости отправляются в сервис создания дайджестов посредством обычного POST запроса. Сам сервис создания дайджестов также написан на Python с использованием Flask для обработки входящих POST запросов. Сервис берет полученные новости, сжимает их в один большой запрос и отдает его большой языковой модели для составления дайджеста. Язык Python и фреймворк Flask были выбраны из-за их простоты и минимализма, что позволяет быстро создавать небольшие микросервисы без лишних сложностей. Мой микросервис не содержит сложных моделей, большого объема кода или необходимости в глубокой настройке, где более тяжеловесные фреймворки, такие как Spring, могли бы быть более оправданы с точки зрения удобства чтения, декомпозиции и дальнейшей поддержки кода. Flask идеально подходит для таких задач, так как он не требует создания множества классов или сложной конфигурации. Вместо этого он позволяет сосредоточиться на реализации конкретной функциональности, не заставляя тратить время на настройку инфраструктуры.

В качестве LLM были выбраны модели llama3 (8 млрд параметров) и qwen2 (32 млрд параметров). Выбор пал именно на эти две модели, т. к. их можно развернуть локально, что убирает необходимость платить за API. Все модели были развернуты с использованием ollama, что в свою очередь обеспечивает возможность обращаться к любой из развернутых моделей используя одну и ту же спецификацию API. Это позволяет обеспечить модульный подход к разработке и развертыванию, что в свою очередь дает возможность легко менять список используемых моделей без необходимости вносить серьёзные изменения в код

микросервиса.

2.4. Создание веб версии корпуса

Для увеличения скорости разработки и упрощения дальнейшей поддержки было принято использовать веб-фреймворк или библиотеку, такую как React. Как результат, выбирать пришлось между Vue.js, React и Angular. Все из перечисленных фреймворков отличаются компонентным подходом — особенностью, когда некоторые блоки кода представляют собой независимые и переиспользуемые элементы, называемые компонентами. Компонент может содержать в себе логику, шаблон и стили, что позволяет разрабатывать интерфейс более модульно и структурировано. Это значительно упрощает тестирование и дальнейшее масштабирование приложения.

Т. к. одной из важных частей исследовательского функционала корпуса является возможность добавления пользователем аннотаций к тексту, важно было выбрать фреймворк, который бы не имел конфликтов с библиотекой для создания аннотаций. В качестве библиотеки для аннотаций было принято решение использовать RecogitoJS из-за ее простоты в использовании, удобстве и реализации большей части необходимого для аннотирования функционала "из коробки". Однако эта библиотека содержит в себе Preact — легковесная и быстрая альтернатива React, которая предоставляет аналогичную функциональность, но имеет меньший размер, что снижает нагрузку на приложение. Проблема заключается в том, что Preact не всегда совместим с некоторыми особенностями React, что усложняет интеграцию с проектом, построенным на React.

Angular тоже не подошел из-за его более тяжелой и монолитной структуры, которая требует значительных усилий для конфигурации и настройки. В отличие от Vue.js, где компоненты можно добавлять и интегрировать по мере необходимости, Angular обладает более сложной системой зависимостей и строгими правилами построения приложений. Это делает его менее гибким для проектов, где важна скорость разработки и возможность быстрой модификации. В добавок Angular известен более медленной скоростью загрузки страниц и более низкой производительностью по сравнению с аналогами.

Как результат, клиентская часть умного корпуса текстов СМИ была реализована с использованием Vue.js и Quasar. Quasar — это фреймворк, построенный на базе Vue.js, который предоставляет набор готовых компонентов и инструментов для создания приложений любого типа: от веб-приложений до мобильных и десктопных. Это решение было выбрано для обеспечения быстрой разработки, высокой производительности и совместимости с различными платформами. Одной из ключевых особенностей Quasar является наличие встроенных компонентов и инструментов для создания адаптивного и многоплатформенного интерфейса, что позволяет значительно сократить время разработки,

снизить вероятность допущения ошибок и создать отзывчивый и интуитивно понятный пользовательский интерфейс, способный адаптироваться под разные устройства. Кроме того, Quasar поддерживает различные темы оформления и легко интегрируется с другими библиотеками и инструментами, что сделало его идеальным выбором для этого проекта. Разработка веб дизайна велась самостоятельно, без готовой фирменной библиотеки компонентов, однако заказчик предоставил ссылку на их брендбук, который описывал основные правила использования символики бренда, давал рекомендации по работе с цветами, и предоставлял ссылки на скачивание логотипа и шрифтов компании.

Большинство взаимодействий пользователя со статьями и дайджестами приводят к формированию соответствующих HTTP-запросов, следующих правилам REST API. REST API (Representational State Transfer API) — это архитектурный стиль взаимодействия между клиентом и сервером, основанный на стандартных HTTP-методах (GET, POST, PUT, DELETE). В REST API каждая сущность (например, статья или дайджест) представляется в виде ресурса, к которому можно обращаться с определёнными запросами. Эти запросы затем отправляются на backend для получения, удаления, редактирования или добавления информации, необходимой пользователю. Полученные запросы, в свою очередь, обрабатываются контроллерами (Spring Controllers). Данные передаются в формате JSON (JavaScript Object Notation) — это легковесный и широко используемый формат обмена данными, который легко читается и обрабатывается как человеком, так и программами. JSON является стандартом для REST API, так как он позволяет эффективно передавать структурированную информацию между клиентом и сервером. Для лучшего понимания взаимодействия клиентской части с серверной предлагаю обратиться к диаграмме прецедентов (рисунок 17).




Рисунок 17 - Диаграмма прецедентов

Выводы по главе

Данная глава описывает основные функциональные требования, предъявляемые к разработанной системе. Помимо этого, в данной главе был обоснован выбор основных архитектурных решений и используемых средств технической реализации. В связи с этим были затронуты некоторые тонкости реализации ключевого функционала и были описаны основные процессы работы отдельных сервисов умного корпуса текстов СМИ.

3. Обзор основного функционала и детали его реализации

3.1. Клиентская часть

3.1.1. Авторизация

Авторизация в корпусе реализована с использованием двух JWT токенов – access и refresh. Access token имеет относительно короткий период жизни – 15 минут, в то время как refresh token остается валидным до 7 дней. Оба токена хранятся в cookie с атрибутом HTTPOnly. Это делает их недоступными для JavaScript на клиентской стороне, защищая их от кражи посредством XSS атак. Оба токена автоматически отправляются на сервер при каждом запросе пользователя, что в свою очередь немного упрощает реализацию клиентской части приложения, т. к. все необходимые данные для аутентификации пользователя уже будут включены в каждый запрос. Как только такой запрос поступает на сервер, происходит валидация access token, если он валиден, то пользователю дают доступ к запрошенному ресурсу. Помимо вышеописанных преимуществ, такой подход также позволяет приостанавливать деятельность аккаунта, если вдруг его активность начнет вызывать подозрения. Т. к. refresh токены хранятся на сервере, в случае обнаружения подозрительной активности, сервер может попросту удалить токен из базы данных и тем самым заставить пользователя пройти повторную аутентификацию.

Сама аутентификация в веб версии происходит на отдельной странице, где пользователю предлагают ввести свой адрес электронной почты и пароль (рисунок 18).




Рисунок 18 - Окно входа в аккаунт

В случае, если пользователь еще не имеет аккаунта в корпусе, он может создать его, введя свое ФИО и придумав пароль.

3.1.2. Домашняя страница

После авторизации пользователь попадает на страницу домой, которая содержит краткое описание корпуса, а также список поддерживаемых источников, где каждый источник представлен своим логотипом (рисунок 19).




Рисунок 19 - Страница "Домой"

Навигация по страницам корпуса осуществляется при помощи верхней навигационной панели, доступной с любой страницы сайта. Эта же навигационная панель, содержит кнопку переключения режима цветовой темы корпуса. На устройствах с меньшими экранами пункты навигационной панели заменяются гамбургер-меню (рисунок 20). Это нужно для того, чтобы все опции панели оставались хорошо читаемыми и доступными для нажатия.




Рисунок 20 - Мобильная версия с закрытым/открытым гамбургер-меню, темная тема

3.1.3. Страница со всеми документами

Страница со всеми новостными статьями открывается при нажатии на секцию “Документы” в верхней навигационной панели и доступна по адресу /documents. Вверху страницы располагается секция с полями для поиска и фильтрации статей. Применение поиска и всех фильтров происходит при нажатии на кнопку “Найти”. Также есть отдельная кнопка для очищения всех заполненных полей. Помимо обычного точного поиска, корпус также поддерживает поиск по id и синтаксический поиск. Последний попытается понять суть запроса, пользователя и выдать именно те статьи, которые больше всего подходят по смыслу. Ниже строки поиска располагается список статей. Для сокращения времени ожидания данных и уменьшения нагрузки на сервер, данная страница использует пагинацию, показывая лишь 20 статей за раз. При нажатии на кнопку “Показать еще”, загружаются следующие 20 статей, удовлетворяющих все тем же заданным пользователем фильтрам. Каждая новость представлена отдельной карточкой (рисунок 21).




Рисунок 21 - Страница поиска и фильтрации новостей

Такая карточка содержит в себе id статьи (используется для поиска по id), источник, дату публикации, название, часть текста, набор тегов, присвоенных статье при классификации. Данная страница доступна даже не для авторизованных пользователей. Однако, если пользователь вошел в аккаунт, то карточки также будут отображать иконку книжной заметки. При нажатии на эту иконку всплывает окно с пользовательскими папками. В этом окне пользователь может добавить выбранную статью в любую из своих папок, создать новую папку или убрать статью из существующей.

3.1.4. Просмотр, редактирование и удаление статьи

При нажатии на кнопку “Посмотреть” у любой из карточек на странице “Документы”, открывается страница с соответствующей статьей. Данная страница содержит текст и название статьи, а дату ее публикации и название источника. Помимо этого, на странице также есть краткое содержание статьи с примерной оценкой времени, необходимого для прочтения этого самого краткого содержания. Эта оценка высчитывается исходя из предположения, что средний человек читает со скоростью 200 слов в минуту. На этой же странице пользователю также предлагают оценить качество присвоенных к статье тегов. Эта оценка, во-первых, служит критерием качества работы сервиса классификации новостей, а во-вторых, может использоваться для отбора примеров корректной классификации, который в дальнейшем могут быть использованы для обучения новых или дообучения старых моделей классификации. На этой же странице располагается все та же иконка книжной закладки, позволяющая сохранить новость в пользовательскую папку. В конце текста всегда располагается ссылка на оригинал статьи. Также внизу есть кнопка – “Читать оригинал”, открывающая оригинал статьи в отдельном окне.

Помимо вышеописанного функционала, данная страница также предоставляет ряд аналитического функционала для работы с текстом. Пользователь может выделять фрагменты текста и добавлять к ним приватные аннотации (рисунок 22).




Рисунок 22 - Страница просмотра новости

Если на фрагменте текста присутствует аннотация, то он выделяется особым цветом. При нажатии на аннотированный фрагмент текста, пользователю дается возможность отредактировать текст аннотации, добавить к аннотации дополнительный комментарий или

вовсе удалить аннотацию. Данный функционал позволяет пользователю выделять ключевые моменты в тексте, комментировать отдельные его части и добавлять дополнительную метаинформацию к написанному. Кроме аннотаций, данная страница также содержит секцию с приватными заметками, которые пользователь может использовать, чтобы зафиксировать свои мысли и идеи, возникшие при прочтении текста. В отличие от аннотаций, заметки не привязаны к какой-то конкретной части статьи, а относятся к тексту в целом.

Важно отметить, что для просмотра этой страницы не нужно входить в свой аккаунт, однако если на страницу зайдет незарегистрированный пользователь, то пользовательский интерфейс будет сильно отличаться. Например, пропадет иконка книжной закладки, строка с рейтингом, а секция с комментариями будет заблокирована плашкой, сообщающей пользователю о том, что ему необходимо войти в аккаунт, чтобы пользоваться всем функционалом страницы (рисунок 23). Пользователь также не сможет оставлять аннотации – при выделении текста, меню аннотаций попросту не будет всплывать.




Рисунок 23 - Страница просмотра статьи для не зарегистрированного пользователя

Если страницу просматривает пользователь с правами администратора, то в пользовательском интерфейсе появляются две дополнительные кнопки – “Редактировать” и “Удалить”. Они нужны на случай, если веб скрапер не смог корректно обработать статью, например захватил вместе с текстом часть рекламы, или вовсе не смог корректно собрать текст или название новости. Данный функционал является особенно важным, ведь структура сайтов-источников может в любой момент измениться и может потребоваться какое-то время, чтобы вновь корректно настроить веб скрапер или хотя бы временно отключить сбор новостей с данного источника. В случае редактирования новости администратор может изменить абсолютно все параметры данной статьи, включая

метаданные, текст и название. Несмотря на то, что права администратора выдаются исключительно доверенным лицам, на отредактированных вручную статьях пишется пометка о том, что они ранее были изменены администрацией. Также хочется добавить, что администратору специально предоставляется возможность сбросить рейтинг качества присвоенных тегов. Это особенно полезно в ситуациях, когда сервис классификации некорректно классифицировал новость, из-за чего она в свою очередь получила плохой рейтинг от пользователей, а администратор в дальнейшем исправил некачественную классификацию, чтобы статью было проще найти при фильтрации по тегам. Тогда получается, что старый плохой рейтинг уже не отображает реальное качество классификации данной новости и его необходимо изменить, чтобы в дальнейшем использовать эту новость с корректной классификацией для составления обучающей выборки для обучения или дообучения классификации корпуса.

Также важно отметить, что при изменении текста статьи, сбрасываются все аннотации, т. к. они напрямую связаны с порядковыми номерами букв в тексте. Для того, чтобы избежать потерю лишних аннотаций, пользовательский интерфейс автоматически предупреждает администратора системы о последствиях изменения текста статьи, если он изменил поле с текстом в процессе редактирования документа. Данное предупреждение реализовано в виде всплывающего меню, где пользователю необходимо подтвердить свои действия (рисунок 24). Аналогичное окно подтверждения появляется при удалении статьи.




Рисунок 24 - Всплывающее окно о последствиях изменения текста на фоне страницы редактирования статьи

3.1.5. Принцип работы подписок и дайджестов

В умном корпусе текстов СМИ дайджесты работают по следующему принципу. Сначала пользователь создает новую подписку либо добавляется в уже существующую. Создатель подписки указывает ее название, описание, модификатор доступа (приватный/публичный) список источников и список тегов. Последние два параметра используются для фильтрации новостей, которые в дальнейшем лягут в основу дайджестов, генерируемых в рамках данной подписки. В конце каждого дня свежие новости удовлетворяющие параметрам подписки будут отправлены с сервера в сервис создания дайджестов, который в свою очередь проанализирует каждую из присланных новостей, и на их основе напишет краткий дайджест. Этот процесс повторяется для практически каждой подписки. Исключением являются только подписки с одинаковым набором источников и тегов, т. к. они по сути будут генерировать дайджесты из абсолютно одинакового набора новостей. Поэтому для уменьшения нагрузки на сервис создания дайджестов, эти подписки будут делить один ежедневный дайджест на всех. При этом все остальные метаданные подписки, не влияющие на результат работы сервиса создания дайджестов, такие как название подписки и ее описание будут оставаться уникальными. После того, как сервис создания дайджестов сгенерировал дайджест, он отправляется в корпус. Если создатель подписки пометил ее как публичную, то сгенерированные в рамках этой подписки дайджесты будут доступны каждому пользователю корпуса через список всех дайджестов. Если же подписка является приватной, то ее дайджесты будут доступны в корпусе только для тех пользователей, кто входит в список подписчиков данной подписки. После того, как дайджест попал в корпус, он рассылается подписчикам в зависимости от их индивидуальных настроек уведомлений. Всего существует два варианта оповещения – через почту и через мобильные уведомления. В первом случае на почту приходит уже готовый дайджест в формате PDF, в случае же с мобильными уведомлениями, пользователю лишь приходит уведомление о том, что появился новый дайджест. О том как именно устроена система отправки уведомлений написано в пункте.

3.1.6. Просмотр дайджестов и подписок

Данная страница является самой большой одновременно по размеру и по количеству предоставляемого функционала пользователю. Вверху страницы есть секция с избранными дайджестами (рисунок 25). Избранными называются те дайджесты, которые были составлены в относительно недавнее время, а также отличились высоким рейтингом и большим количеством оценок. В избранные могут входить, как и публичные дайджесты других пользователей, как и дайджесты, заказанные самим корпусом. Сама секция представлена в виде само крутящейся карусели, где каждый дайджест представляет собой отдельный слайд, поделенный на две части. Левая часть содержит метаинформацию о дайджесте, а правая фотографию, ассоциируемую с ним. Фотография, выбирается корпусом автоматически на основе тегов этого дайджеста.




Рисунок 25 - Страница "Дайджесты"

Ниже секции с избранными дайджестами располагается секция с подписками. Тут пользователь может управлять статусом своей подписки на рассылку дайджестов. Каждая подписка представлена карточкой, содержащей название подписки, описание и основную метаинформацию: дату создания подписки, модификатор доступа, создателя подписки, теги и источники. Помимо этого, рядом с названием подписки есть кнопка – “Управлять подпиской”. При нажатии на эту кнопку открывается выпадающее меню, где пользователь может изменить параметры уведомлений, а также вовсе отписаться от данной подписки (рисунок 26). Ради экономии места, в секции с подписками всегда отображается только первые две подписки, однако, если пользователь захочет посмотреть весь список целиком, то он может нажать на кнопку “Показать еще”, чтобы отобразить сразу все свои подписки.




Рисунок 26 - Список подписок

Для незарегистрированных пользователей, вместо секции с подписками находится плашка, сообщающая пользователю о необходимости войти в аккаунт, чтобы пользоваться системой подписок и другим важным функционалом корпуса. Данная плашка аналогична той, что была ранее описана в пункте 3.4.

Ниже секции с подписками располагается раздел со списком всех дайджестов. Вверху списка располагается секция с полями для поиска и фильтрации аналогично той, что была на странице со списком всех документов, описанной в пункте 3.3. Ниже находится непосредственно сам список дайджестов. Каждый дайджест там представлен в виде отдельной карточки (рисунок 27).




Рисунок 27 - Список дайджестов

Каждая такая карточка содержит набор источников и тегов, название, текст дайджеста, а также его id, дату формирования, средний рейтинг и параметры уведомлений пользователя по отношению к подписке, к которой относится данный дайджест. Помимо этого, каждая карточка дополнительно имеет две кнопки – “Скачать PDF” и “Посмотреть”. Первая скачивает PDF версию текущего дайджеста, в то время как вторая, открывает страницу просмотра этого дайджеста.

3.1.7. Просмотр дайджеста

Страница просмотра дайджеста содержит все ту же метаданные, что и карточка дайджеста, описанная в пункте выше. На этой странице пользователь может ознакомиться с полным текстом дайджеста, а также дать ему оценку (рисунок 28). Также, как и в случае с оценкой классификации, оценка качества дайджеста будет использована для дальнейшего совершенствования используемых корпусом моделей машинного обучения. С этой страницы также доступна кнопка изменения параметров подписки, к которой относится данный дайджест, более детально описанной в пункте 3.6. Внизу страницы, сразу под тегами располагается аккордеон, содержащий ссылки на те новости, из которых был составлен данный дайджест. Важно отметить, что незарегистрированные пользователи могут просматривать публичные дайджесты, но не могут оставлять им оценки, для них компонент с рейтингом будет попросту отсутствовать на странице.




Рисунок 28 - Просмотр дайджеста

3.1.8. Система управления уведомлениями

Всего умный корпус текстов СМИ содержит два типа уведомлений – мобильные и через почту. Настроить данные параметры можно сразу в нескольких местах. Все эти места имеют определенную иерархию (рисунок 29).




Рисунок 29 - Иерархия настроек уведомлений

Самыми приоритетными настройками являются те, которые пользователь вручную указывает для какой-то конкретной подписки (рисунок 26). Сделать это можно либо из секции “Мои подписки”, либо из страницы просмотра конкретного дайджеста. Затем идут те параметры, которые пользователь указывает в настройках профиля. Всего в настройках профиля есть три основные секции, связанные с конфигурацией уведомлений. Первая – это настройки автоматической подписки. Это те настройки, которые корпус автоматически применяет к подписке, когда пользователь подписывается на нее. Вторая секция – это просто чекбокс, дающий возможность разрешить/запретить другим пользователям добавлять текущего пользователя в свои подписки. Дело в том, что при создании новой подписки, пользователь может сразу указать список ее получателей, а также выставить им параметры уведомлений. Если пользователь не разрешил добавлять себя в чужие подписки, то корпус просто не даст другому пользователю добавить его, выдав соответствующую ошибку. Подробнее о том, как происходит добавление пользователя написано в следующем пункте. Ну и наконец третья секция становится доступной для конфигурации лишь тогда, когда пользователь разрешил добавлять себя в чужие подписки в предыдущей секции. Данная секция позволяет пользователю определить, с какими именно параметрами его можно добавлять в чужие рассылки. Данная система наглядней всего демонстрируется на конкретном примере. Предположим, в настройках уведомлений пользователя указано, что

его можно добавлять в другие дайджесты с уведомлениями на почту, но без уведомлений через мобильное приложение. Коллега пользователя коллега создал подписку и добавил пользователя вместе с другими коллегами в качестве получателя ее дайджестов. В качестве параметров уведомлений он указал, отправку уведомлений в мобильное приложение и на электронную почту. Т. к. у пользователя выключено получение уведомлений в мобильное приложение для посторонних дайджестов, он не будет их получать. Однако если в будущем пользователь все-таки захочет получать мобильные уведомления именно от этой подписки, то он сможет это сделать в параметрах уведомлений этой самой подписки.

3.1.9. Создание/редактирование подписки

Создание собственной подписки реализовано через страницу “Заказ дайджеста”. Попасть на эту страницу можно, нажав на кнопку “Создать дайджест” в секции с подписками, описанной в пункте 3.6. Т. к. эта секция отображается только для зарегистрированных пользователей, попасть на данную страницу можно лишь авторизованным пользователям. Соответствующий endpoint /subscriptions/create также является защищенным. На данной странице пользователю предлагается указать всю необходимую информацию для создания его собственных дайджестов (рисунок 30).

Рисунок 30 - Страница создания подписки

Подробнее о том, как в корпусе работает система подписок можно в рассмотренном ранее пункте 3.5. Одним из ключевых аспектов этой страницы является поле с подписчиками дайджеста. Создатель подписки способен добавить сторонних получателей через их адрес электронной почты при условии, что в их настройках уведомлений включена такая возможность (см пункт 3.8). Для того, чтобы это сделать пользователь вводит адрес электронной почты в поле для ввода, после чего этот адрес передается на сервер для

валидации. Если пользователь с таким адресом действительно существует в корпусе и при этом он разрешил другим пользователям добавлять себя в их подписки, то сервер возвращает ответ 200 и добавление пользователя происходит успешно. В таком случае под полем для ввода адреса электронной почты получателей появляется почта добавившегося пользователя. Рядом с ней могут располагаться до 3 иконок. Наличие иконки почты или телефона означает, что пользователь разрешил получать соответствующий тип уведомлений при добавлении в чужие дайджесты. Последняя же иконка – иконка крестика позволяет удалить данного пользователя из списка получателей. Добавить одного и того же пользователя дважды невозможно. Добавленного пользователя можно удалить.

Страница редактирования дайджеста практически ничем не отличается от страницы его создания. Единственным отличием является появление дополнительной иконки рядом с почтой подписчиков (рисунок 31).




Рисунок 31 - Иконка стрелочки рядом с почтой подписчика

Данная иконка позволяет передать права владельца дайджеста другому пользователю. После нажатия на эту стрелочку появляется всплывающее окно с просьбой подтвердить данное действие (рисунок 32). Однако важно отметить, что данное изменение не вступит в силу до тех пор, пока пользователь не нажмет кнопку сохранения в левом нижнем углу страницы. После передачи прав создателя и нажатии кнопки “Сохранить изменения”, предыдущий владелец уже не сможет редактировать параметры данной подписки.




Рисунок 32 - Окно подтверждения передачи прав владельца дайджеста другому пользователю

Еще одним сценарием, когда текущему владельцу подписки потребуется передать свои права другому пользователю является случай, когда текущий владелец решает отписаться от подписки, на которую подписаны другие пользователи. В таком случае всплывает меню, где пользователя просят выбрать, кому именно передать права владельца (рисунок 33).




Рисунок 33 - Меню передачи прав владельца в случае, если старый владелец отписался

3.1.10. Выгрузка статей из корпуса

Умный корпус текстов СМИ позволяет своим пользователям выгружать текста, организованные в пользовательские папки в формате JSON. Делается это в настройках профиля в секции “Управление папками” (рисунок 34). Там же можно изменить название пользовательских папок или вовсе их удалить. Пользователь также может включить в результирующую выгрузку свои аннотации, указав соответствующую опцию в пользовательском интерфейсе.

Управление папками




Рисунок 34 - Управление папками

3.2. Сервис для автоматического сбора и обработки новостей

Как уже было упомянуто во второй главе, сервис автоматического сбора и обработки новостей состоит из 4 микросервисов: веб скрапер, сервис классификации, сервис составления дайджестов и сервис отправки писем. В этом пункте мы детально рассмотрим работу каждого из сервисов.

3.2.1. Веб скрапер

Сперва веб-скрапер собирает список ссылок на свежие новости для нужного источника. Для реализации этого функционала требуется индивидуальный подход к каждому сайту, ведь разные источники имеют разные HTML-структуры. Некоторые сайты содержат динамически загружаемый контент, поэтому для их обработки используются отдельные инструменты, такие как Playwright. После того как мы получаем список всех ссылок для какого-то источника, мы начинаем поочередно обрабатывать каждую ссылку для получения содержания статьи. Выгрузка текста статьи также сильно зависит от источника: для некоторых сайтов можно использовать библиотеки, такие как Newspaper3k, а для других приходится собирать данные вручную, изучая HTML структуру сайта и используя BeautifulSoup для обращения к элементам, содержащим нужный нам текст. Перед передачей данных в kafka, новость, в зависимости от ее источника, может проходить небольшую предобработку, которая уберет HTML теги, попавшие в текст статьи.

3.2.2. Kafka

Содержимое статьи и вся собранная метainформация помещаются в класс Article, данные которого записываются в Kafka. Тут важно отметить, что новости поступают в kafka одна за другой, это позволяет модели классификации постепенно классифицировать новости одну за другой, не дожидаясь завершения обработки всех новостей. Kafka в данном случае не только обеспечивает плавную передачу новостей от скрапера к классификатору, но и позволяет этим сервисам работать асинхронно и независимо друг от друга. Например, если сервер классификации перегружен или не работает вовсе, веб-скрапер продолжит собирать информацию, которая будет сохранена в Kafka до тех пор, пока сервис классификации не завершит обработку. Такой подход значительно повышает отказоустойчивость системы и позволяет каждому сервису работать в своем темпе.

3.2.3. Сервис классификации

При классификации используется модель qwen2 с 32 миллиардом параметров. Если модель не смогла классифицировать данную новость, то эта задача падает на запасную модель llama3 с 8 миллиардами параметров. Если обе модели не справляются, то статье присваивается один единственный тег – “Не определено” и новость все равно попадает на

бекенд. В дальнейшем можно будет добавить ряд дополнительных запасных моделей и расширить перечень тегов, чтобы минимизировать перечень моделей с тегом “не определено”. После завершения работы сервиса классификации он отправляет статью вместе с результатами классификации и прочей метаинформацией на бэкенд, который сохраняет полученную информацию в своей базе данных и делает ее доступной для просмотра на веб-версии и в мобильном приложении.

3.2.4. Сервис создания дайджестов

Под конец дня бэкенд отправляет текст и краткое содержание статей с определенными тегами и из определенных источников сервису по созданию дайджестов, который с помощью LLM обобщает статьи и генерирует краткий дайджест. Важно заметить, что никаких других метаданных, таких как источник или список тегов сервису не отправляются. Краткое содержание же нужно отправлять на случай, если текст запроса к большой языковой модели становится слишком большим. В таком случае вместо текста статей LLM получает на вход их краткое содержание. На выход из большой языковой модели мы получаем готовый дайджест. После краткой валидации этот дайджест затем отправляется обратно на сервер, рассылается на почту подписчикам и становится доступным для просмотра на веб-версии и в мобильном приложении. Для генерации дайджеста используются все те же модели, что и при классификации, только с другими инструкциями.

3.2.5. Сервис отправки писем

Данный сервис необходим для рассылки дайджестов на почту получателей, а также для подтверждения адреса электронной почты пользователя при его регистрации. В последнем случае сервис отправляет шестизначный код на почту получателя, который необходимо ввести на странице верификации почты. Не верифицировав почту, пользователь не сможет получать рассылки дайджестов на указанный адрес. Сам код генерируется бекендом и приходит к сервису вместе с электронным адресом получателя в формате POST HTTP запроса.

Выводы по главе

В данной главе был произведен обзор ключевого функционала корпуса, а также рассмотрены детали его реализации. Был произведен детальный разбор основных страниц клиентской части умного корпуса СМИ с подробным описанием их назначения и принципа использования. Также были описаны основные алгоритмы работы веб скрпера, сервиса классификации и сервиса составления дайджестов. Как видно, веб версия корпуса отличается современным и интуитивно понятным пользовательским интерфейсом и

полностью покрывает весь функционал, необходимый заказчику – АО «ТБАНК», а также соответствует всем требованиям, описанным в документе «Клиентская часть умного корпуса текстов СМИ и сервис для автоматического сбора и обработки новостей. Техническое задание».

Заключение

Первым результатом ВКР является веб версия умного корпуса текстов СМИ, которая позволяет пользователям просматривать новости из большого спектра источников, добавлять к ним персональные заметки и аннотации, а также организовывать их в папки с возможностью дальнейшей выгрузки. Навигация по статьям реализована через инструменты фильтрации и поиска. Поиск поддерживает три режима работы: точный, по ID и синтаксический. Веб версия корпуса также позволяет пользователям заказывать составление ежедневных персонализированных дайджестов – выжимок из новостей по заданной тематике, взятых из определённого набора источников. Пользователи могут просматривать эти дайджесты, выгружать их в PDF и заказывать их получение на электронную почту. Помимо этого, веб версия позволяет пользователям настраивать свой аккаунт и параметры входа в него, а также просматривать сервис со статистикой.

Вторым результатом является сервис для автоматического сбора и обработки новостей, который в автоматическом режиме собирает и классифицирует новости из определенного набора источников. Этот же сервис используется для составления персонализированных дайджестов и их последующей отправке на почту читателей.

Разработанные в рамках ВКР компоненты, совместно с набором сервисов, реализуемых другими членами команды, образуют одну единую систему, позволяющую пользователям получать интересующую их информацию в сжатом и удобном для чтения виде, что позволяет им оставаться в курсе последних событий, не тратя большое количество времени на чтение каждой статьи отдельно.

В дальнейшем планируется расширить список поддерживаемых источников и добавить поддержку обработки других форматов данных, например чтение PDF отчетов, сбор информации из видеороликов, а также мониторинг социальных сетей и мессенджеров. Помимо этого, предлагается использовать выборку, полученную благодаря работе системы рейтинга, позволяющей получить оценку качества классификации статей и составления дайджестов для дообучения больших языковых моделей и их дальнейшего применения в корпусе. Это в свою очередь должно привести к росту качества работы разработанного продукта.

Как итог, разработанное ПО отвечает всем требованиям заказчика - АО "ТБАНК" и может быть использовано внутри организации для автоматизированного мониторинга СМИ и предоставления сотрудникам организации релевантных новостных выжимок.

Источники

1. About flipboard [Электронный ресурс] - URL: <https://about.flipboard.com/> режим доступа: свободный (дата обращения: 18.11.2024)
2. Angular vs vue: A head-to-head comparison [Электронный ресурс] – URL: <https://kinsta.com/blog/angular-vs-vue/>
3. Apache AirFlow Documentation [Электронный ресурс] – URL: <https://airflow.apache.org/docs/> режим доступа: свободный (дата обращения: 18.11.2024).
4. Apache Kafka Documentation [Электронный ресурс] – URL: <https://kafka.apache.org/documentation/> режим доступа: свободный (дата обращения: 16.11.2024).
5. Docker Documentation [Электронный ресурс] – URL: <https://docs.docker.com/> (дата обращения: 27.02.2025).
6. PostgreSQL Documentation [Электронный ресурс] – URL: <https://feedly.com/i/my/me> (дата обращения: 12.04.2023).
7. Flask Documentation [Электронный ресурс] – URL: <https://flask.palletsprojects.com/en/2.0.x/> (дата обращения: 09.01.2025).
8. How to build a CI/CD pipeline with GitHub Actions in four simple steps [Электронный ресурс] – URL: <https://github.blog/enterprise-software/ci-cd/build-ci-cd-pipeline-github-actions-four-steps/> (дата обращения: 16.11.2024).
9. GitHub [Электронный ресурс] – URL: <https://github.com/> режим доступа: свободный (дата обращения: 18.11.2024).
10. JavaScript Documentation [Электронный ресурс] – URL: <https://developer.mozilla.org/en-US/docs/Web/JavaScript> (дата обращения: 12.10.2024).
11. Newspaper3k Documentation [Электронный ресурс] – URL: <https://newspaper.readthedocs.io/en/latest/> режим доступа: свободный (дата обращения: 18.11.2024).
12. Preact framework [Электронный ресурс] – URL: <https://preactjs.com/> режим доступа: свободный (дата обращения: 18.11.2024).
13. Python Documentation [Электронный ресурс] – URL: <https://www.python.org/doc/> режим доступа: свободный (дата обращения: 18.11.2024).
14. React [Электронный ресурс] – URL: <https://react.dev/> режим доступа: свободный (дата обращения: 18.11.2024).
15. Seldon Group [Электронный ресурс] – URL: <https://seldongroup.ru/system/news> (дата обращения: 12.10.2024).

16. Smart News [Электронный ресурс] – URL: <https://www.smartnews.com/en> (дата обращения: 12.10.2024).
17. uCrawler help center [Электронный ресурс] – URL: <https://ucrawler.app/help-center-pro> (дата обращения: 10.10.2024).
18. Vue.js [Электронный ресурс] - URL: <https://vuejs.org/> режим доступа: свободный (дата обращения: 18.11.2024)
19. Дзен [Электронный ресурс] – URL: <https://dzen.ru/> режим доступа: свободный (дата обращения: 18.10.2024).
20. Репозиторий RecogitoJS [Электронный ресурс] – URL: <https://github.com/recogito/recogito-js> режим доступа: свободный (дата обращения: 18.11.2024).